

AI 반도체 자원 풀링을 위한 시공간 통합 관리 아키텍처에 관한 연구

안성모, 안재훈, 김영환

한국전자기술연구원 지능형 IDC 사업단

(seongmo619, corehun, yhkim)@keti.re.kr

A Study on the Spatio-Temporal Integrated Management Architecture for AI Semiconductor Resource Pooling

Seongmo Ahn, JaeHoon An, YoungHwan Kim

Intelligent IDC Project Office, Korea Electronics Technology Institute

요 약

거대언어모델(LLM)과 같은 대규모 AI 모델의 확산은 기존 데이터센터의 정적 자원 할당 방식의 비효율성을 드러내고 있다. 고가의 AI 가속기 활용률은 저조하고 운영 비용은 증가하는 문제가 발생하고 있다. 본 논문은 이러한 한계를 극복하기 위해 설계된 '시공간 통합 컴퓨팅 자원 관리 아키텍처'를 제안한다. 본 아키텍처는 워크로드 프로파일링, 시공간 자원 분해, 동적 자원 공유 비율 변경이라는 세 가지 핵심 기술을 기반으로 한다. 구체적으로, 예측과 실시간 보정을 결합한 프로파일링으로 워크로드 요구사항을 분석하고, 물리적 AI 가속기를 미세 단위의 논리 자원으로 분해하여 시공간적으로 공유하며, 실시간 변화에 맞춰 자원 할당을 동적으로 최적화한다. 클라우드 네이티브 쿠버네티스(Kubernetes) 환경 내에서 다양한 LLM 워크로드에 대한 자원 활용률과 성능을 극대화함으로써, 본 시스템은 모놀리식(monolithic) 인프라의 경직성을 탈피하는 유연하고 효율적인 대안을 제시한다.

I. 서론

현대의 AI 인프라는 고성능 가속기(GPU, NPU 등)가 호스트 CPU 및 메모리에 물리적으로 종속된 모놀리식 서버 설계가 지배적이다. 이러한 경직된 결합 구조는 심각한 자원 낭비를 초래한다. [1] 예를 들어, 메모리 중심적(memory-bound) 작업은 연산 코어를 유휴 상태로 남겨두고, 연산 중심적(compute-bound) 작업은 메모리 대역폭을 충분히 활용하지 못하는 자원 고립 현상이 발생한다. 특히 LLM의 학습, 추론 등 다양하고 동적인 워크로드 요구사항에 정적 할당 방식은 효과적으로 대응하기 어려워, 고가의 AI 하드웨어 도입에 따른 총소유비용(TCO) 대비 효율성이 저하되는 문제를 안고 있다. [2]

이러한 문제에 대한 해결책으로 '자원 분해' 기술이 부상하고 있다. 이는 연산, 메모리, I/O 자원을 논리적, 물리적으로 분리하여 네트워크로 연결된 자원 풀(pool)로 구성하는 패러다임이다. 이 기술은 애플리케이션 요구에 따라 필요한 자원만 정확하게 조합하여 가상 서버를 동적으로 구성하는 인프라 구조를 가능하게 한다.

본 논문은 자원 분해 환경에서 분산된 AI 자원을 효과적으로 오케스트레이션하기 위한 소프트웨어 정의 관리 아키텍처를 상세히 기술한다. 이 아키텍처의 독창성은 자원을 공간과 시간의 두 축에서 통합적으로 관리하여 효율성을 극대화하고 다양한 워크로드의 서비스 수준 목표를 충족시키는 데 있다. 본 시스템의 핵심 기술은 (1) 워크로드 프로파일링, (2) 시공간 자원 분해, (3) 동적 자원 공유 비율 변경 기술로 구성된다. 이는 단순한 자원 풀 관리를 넘어, 워크로드 특성을 지능적으로 분석하여(워크로드 프로파일링), 자원을 미세 단위로 분해하고 시공간적으로 공유하며(시공간 자원 분해), 실시간 변화에 대응하여 자원 할당을 동적으로 최적화하는(동적 자원 공유 비율 변경) 지능형 오케스트레이션을 통해 자원 가용성을 워크로드 중심의 최적화로 전환한다.

II. 본론

2.1 시스템 아키텍처

본 시스템은 의사결정을 담당하는 컨트롤 플레인(Control Plane)과 실제 워크로드를 실행하는 데이터 플레인(Data Plane)으로 구성된다. 관리 아키텍처는 컨트롤 플레인에 위치하며, 워크로드 분석, 스케줄링, 자원 할당의 전 과정을 책임진다. 사용자로부터 LLM 작업 요청이 들어오면, 컨트롤 플레인은 해당 요청을 프로파일링하고, 자원 풀에서 필요한 자원을 할당할 수, 데이터 플레인의 가상 AI 가속기(vGPU, vNPU 등)에서 실행되도록 작업을 분배한다. 이 구조는 관리 로직과 실행 환경을 명확히 분리하여 시스템의 모듈성과 확장성을 보장한다.




[그림 1] AI 반도체 자원 풀링 아키텍처 개요

2.2 워크로드 프로파일링

워크로드 프로파일링 기술은 연산 그래프 분석 결과를 기반으로 워크로드의 타입을 식별하고, 그 결과를 바탕으로 연산 요구 사항과 실행 패턴을 분석하여 최종적으로 워크로드의 우선순위를 결정하는 핵심 기술이다.

프로세스는 먼저 연산 그래프 분석을 통해 제출된 작업이 학습(Training), 추론(Inference), 전처리(Pre-process)인지 등 타입을 식별하


는 것에서 시작한다. 다음으로, 식별된 타입을 근거하여 작업이 연산 중심적(Compute-bound)인지, 메모리 중심적(Memory-bound)인지 등 구체적인 연산 요구 사항을 분석한다. 이어서 반복성, 지연 시간 민감도, 처리량 요구 등 워크로드의 고유한 실행 패턴을 파악한다. 최종적으로, 이러한 다각적인 분석 결과를 종합하여 워크로드의 우선순위를 결정한다. 이 과정을 통해 시스템은 각기 다른 특성을 가진 워크로드에 대해 최적의 자원을 선별적으로 할당할 수 있게 된다.



[그림 2] 연산 그래프 분석을 통한 워크로드 프로파일링

2.3 시공간 자원 분해

본 아키텍처의 근간은 물리적 하드웨어를 미세 단위의 논리 자원으로 분해하는 능력에 있다. [3][4] 예를 들어, 하나의 물리 GPU는 컴퓨팅 유닛에 대한 시분할 점유율을 나타내는 *temporal.gpu.com/percent*로 추상화된다. 이렇게 정의된 논리 자원들은 Custom Device Plugin을 통해 쿠버네티스 스케줄러에 등록된다. 이러한 접근 방식은 DevOps팀이나 오케스트레이션 시스템이 복잡한 공유 메커니즘을 알 필요 없이, 표준 쿠버네티스 메니페스트를 사용해 미세 단위의 분할된 AI 자원을 요청할 수 있게 한다.



[그림 3] 하드웨어 자원 미세 단위 분해

이렇게 분해된 자원들을 관리하는 시공간 공유 엔진은 자원 할당 메커니즘의 핵심으로, 여러 워크로드가 단일 물리 가속기를 동시에 공유할 수 있게 한다. 시간적 공유(Temporal Sharing)는 워크로드들을 시간 축에서 다중화하여 지연 시간에 민감한 추론 작업과 처리량 중심의 학습 작업을 교차 실행하여 전체 처리량을 극대화한다. 공간적 공유(Spatial Sharing)는 NPU 코어나 가속기 메모리(VRAM)와 같은 자원을 격리된 세그먼트로 분할하여 각 워크로드에 전담시켜 멀티테넌트 환경의 안정성을 확보한다.

2.4 동적 자원 공유 비율 변경 기술

본 기술의 핵심은 여러 워크로드가 단일 물리 가속기를 효율적으로 공유하도록 하는 이상적인 시공간 공유 모델에 있다. [5] 이는 시간 공유 기술

과 공간 공유 기술의 유기적인 결합을 통해 자원 사용률을 극대화한다. 먼저, 워크로드 커널 그룹 실행 기반 시간 공유 기술은 개별 커널 호출마다 컨텍스트를 전환하는 대신, 여러 커널을 하나의 그룹으로 묶어 실행함으로써 잦은 컨텍스트 전환(Context Switch)으로 인한 오버헤드를 최소화한다. 이를 통해 지연 시간에 민감한 추론 작업과 처리량 중심의 학습 작업을 효과적으로 교차 실행하여 전체 시스템의 처리량을 높인다.

다음으로, 공간 자원 재구성 기반 공간 공유 기술은 물리적 자원을 공간적으로 분할한다. 예를 들어, GPU의 SM과 VRAM을 재구성 가능한 독립된 논리적 파티션으로 나누고, 각 워크로드에 특정 비율(예: Workload A에 SM 40%)을 할당한다.

이 두 기술을 통합한 시공간 공유를 통해, 서로 다른 공간적 자원 요구사항을 가진 워크로드들이 시간의 흐름에 따라 빈틈없이 교차 실행되면서 유휴 자원을 최소화하고 가속기 전체의 활용률을 극대화한다. 이러한 공간적 분할 비율과 시간적 실행 순서는 고정된 것이 아니라, 워크로드 프로파일링 결과와 실시간 모니터링 데이터를 기반으로 동적으로 변경된다. 이를 통해 하드웨어 자원의 유연한 제어가 가능하다.

III. 결론

본 논문은 분해된 AI 가속기를 위한 새로운 시공간 통합 관리 아키텍처를 제안한다. 워크로드 프로파일러, 쿠버네티스 네이티브 자원 추상화, 그리고 동적 제어 메커니즘을 통해, 본 아키텍처는 AI 자원 활용률을 크게 향상시키고, 스케줄링 지연을 단축하며, LLM 워크로드에 대한 데이터 센터의 총소유비용을 절감할 것으로 기대된다. 이 기술은 모놀리식 AI 인프라의 한계를 극복하고 차세대 AI 데이터센터로 나아갈 경로를 제시한다. 향후 본 기술의 개발 로드맵은 단일 노드 프로토타입에서 시작하여 다중 노드의 이기종 환경으로 점진적으로 확장하는 것을 목표로 한다. 주요 과제는 다양한 제조사의 GPU, NPU, PIM 등을 포함하는 이기종 자원 풀을 통합 관리하고, CXL 기반 메모리 풀링과 연동하여 완벽하게 분해된 컴퓨팅 환경을 구축하는 것이다. 최종적으로 개발된 아키텍처를 대규모 멀티-랙 환경으로 확장하여 차세대 AI 데이터센터의 참조 모델을 제공하고자 한다.

ACKNOWLEDGMENT

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임 (No.RS-2025-02220502, AI 반도체 컴퓨팅 자원분배 및 자원풀링 기술 개발)

참 고 문 헌

- [1] M. Jeon, S. Venkataraman, A. Phanishayee, J. Qian, W. Xiao, and F. Yang, "Analysis of Large-Scale Multi-Tenant GPU Clusters for DNN Training Workloads," in Proc. USENIX Annu. Tech. Conf. (USENIX ATC), Renton, WA, USA, Jul. 2019, pp. 947 - 960.
- [2] Z. Ye, S. Chen, T. Yu, and X. Wu, "Deep Learning Workload Scheduling in GPU Datacenters: A Survey," ACM Comput. Surv., vol. 56, no. 6, art. 146, pp. 1 - 38, Jun. 2024.
- [3] F. Strati, A. Sotiropoulos, P. Pandey, M. S. Andersen, S. Z. György, and A. Katevenis, "Orion: Interference-aware, Fine-grained GPU Sharing for ML Applications," in Proc. Eur. Conf. Comput. Syst. (EuroSys), Athens, Greece, Apr. 2024, pp. 18:1 - 18:18.
- [4] P. Yu and M. Chowdhury, "Salus: Fine-Grained GPU Sharing

Primitives for Deep Learning Applications,” in Proc. MLSys Conf., Austin, TX, USA, Mar. 2020, pp. 1 - 14.

[5] Xianzhe Ma et al., “Towards Efficient and Practical GPU Multitasking in the Era of LLM,” arXiv preprint 2508.08448, 2025